

ACADEMIA DE STUDII ECONOMICE DIN BUCUREŞTI
FACULTATEA DE CIBERNETICĂ, STATISTICĂ ȘI INFORMATICĂ
ECONOMICĂ
SPECIALIZAREA CIBERNETICĂ ECONOMICĂ

PROIECT LA DISCIPLINA SERII DE TIMP

**EFECTELE CRIZELOR ECONOMICE ASUPRA SITUAȚIEI
MACROECONOMICE A ROMÂNIEI**

Profesor coordonator:

Prof. Univ. Dr. DAVIDESCU ADRIANA-ANAMARIA

Studenti:

LUNGU VANESA-DENISA

Bucureşti

2025

CUPRINS

INTRODUCERE	3
CAPITOLUL 1: ASPECTE TEORETICE.....	4
1.1 Criza economică mondială din 2007-2009.....	5
1.2 Criza economică cauzată de pandemia COVID-19.....	6
CAPITOLUL 2: SERII UNIVARIATE	7
2.1. Verificarea existenței unui trend determinist sau stochastic în evoluția inflației	7
2.2. Verificarea staționarității seriei inflației	9
2.3. Tehnici de netezire exponențială: Model Holt-Winters	12
2.4. Modele ARMA/ARIMA/SARIMA.....	16
➤ Testul Ljung-Box – pentru autocorelarea reziduurilor.....	20
➤ Testul Jarque-Bera – pentru normalitatea reziduurilor	22
➤ Testul ARCH – pentru heteroscedasticitate	23
2.5. Predicția punctuală și predicția pe interval de încredere cu delimitarea setului de training, test si orizontului de prognoza.....	23
2.6. Compararea diferitelor metode univariate de prognoza(ex.SARIMA SI HW) din punct de vedere al acuratetei prognozei.....	26
CAPITOLUL 3: SERII MULTIVARIATE	30
3.1 Analiza de non-stationaritate	30
3.2 Analiza de cointegrare	32
3.3 Modelul VAR	33
3.4 Testul de cauzalitate Granger	35
3.5 Functia de raspuns la impuls (IRF)	36
3.6 Descompunerea variantei	38
CONCLUZII	40
LISTĂ DE TABELE	41
LISTĂ DE FIGURI	42
ANEXE	44
BIBLIOGRAFIE:.....	45

INTRODUCERE

Crizele economice reprezintă fenomene inevitabile în economie, având un impact semnificativ asupra stabilității macroeconomice și financiare. Acestea pot fi declanșate de factori interni sau externi, iar efectele lor se resimt atât la nivelul piețelor financiare, cât și asupra principalilor indicatori macroeconomici.

Am decis să abordăm această temă, deoarece impactul crizelor economice asupra economiei României a devenit o preocupare majoră în contextul stabilității economice. Scopul acestei lucrări este de a analiza modul în care diferite crize economice au influențat stabilitatea macroeconomică a României, evidențiind principalele moduri în care acestea afectează economia și identificând măsurile adoptate pentru atenuarea impactului.

Pentru această analiză se vor utiliza date statistice relevante, precum PIB-ul, variația procentuală a PIB-ului, rata inflației, rata dobânzii, IRCC, cursul valutar euro/leu, rata șomajului. Aceste date vor fi analizate cu ajutorul programului R, aplicând metode statistice descriptive, modele de regresie liniară și din analiza seriilor de timp pentru a identifica și evidenția relațiile și corelațiile existente între variabile.

Primul capitol va introduce conceptele teoretice legate de crizele economice, prezentând totodată evenimentele semnificative și efectele lor asupra macroeconomiei României.

Capitolul al doilea va descrie metodele utilizate în analiza seriilor univariate (ARIMA, SARIMA, Holt-Winters), evidențiind rezultatele și concluziile economice pe baza acestora.

Capitolul al treilea va cuprinde metodele utilizate în analiza seriilor multivariate (VAR, VECM, analiza de cauzalitate Granger, funcția de răspuns la impuls și analiza de descompunere a varianței), evidențiind rezultatele și concluziile economice pe baza acestor metode.

CAPITOLUL 1

ASPECTE TEORETICE

Conform dicționarului juridic Rubinian, criza economică reprezintă o „Situatie în care economia unei țări trece brusc printr-o scădere a forței sale, scădere adusă de regulă de o criză financiară.”¹

De asemenea, se spune că „O economie ce trece printr-o criză economică va experimenta aproape sigur o scădere a PIB (Produs Intern Brut), o evaporare a lichidităților și o creștere / scădere a prețurilor din cauza unei inflații / deflații.”², acestea fiind unele dintre efectele crizelor economice.

Același dicționar definește criza financiară ca fiind o „Situatie în care cererea de bani este mai mare decât oferta (disponibilul) de bani. Aceasta înseamnă că lichiditatea este rapid evaporată deoarece banii disponibili sunt retrăși din bănci, foțând astfel băncile fie să vândă propriile active și investițiile, pentru a-și acoperi necesitățile, sau să colapseze.”³ și poate conduce la o criză economică.

Un tip sever de criză economică este depresiunea economică, fiind considerată o „formă rară dar extremă de recesiune, fiind caracterizată în principal de o creștere "neobișnuită" a ratei şomajului, restricționarea creditelor, restrângerea majoră a producției industriale și a investițiilor, deflația prețurilor, hiperinflație, numeroase falimente bancare, schimburi comerciale semnificativ reduse, un curs valutar foarte volatil și unpredictibil, în principal cu tendință de devalorizare; apare dacă există un declin al produsului intern brut (PIB) mai mare de 10% (o creștere negativă a produsului intern brut timp de cel puțin două trimestre).”⁴

Cele două mari categorii de modele ce vizează crizele financiare sunt:

1), „Modele bazate pe ipoteza tulburării echilibrului pieței monetare și financiare conform curentului principal de găndire care consideră această piață autoreglabilă, că agenții ar avea așteptări raționale iar criza ar fi un fenomen temporar provocat de șocuri exogene, acestea fiind

¹ Dictionar juridic Rubinian, https://www.rubinian.com/dictionar_detalii.php?id=4431

² Ibidem

³ Ibidem

⁴ Ibidem

puse în centrul analizei ciclului și instabilității financiare”⁵ (aceste modele includ modelul lui Paul Krugman „A Model of Balance of Payments Crises” din 1979 și modelul lui Flood și Garber „Collapsing Exchange Rate Regimes: Some Linear Examples” din 1984;

2), Modele bazate pe ipoteza instabilității financiare care iau în considerare atât dinamica piețelor financiare ca procese și instituții, cât și rolul fundamental al incertitudinii, interdependențelor și complexității dinamice a proceselor financiare în relație cu cele ale economiei reale.”⁶

1.1 Criza economică mondială din 2007-2009

- **Originea și impactul global:** Criza a început în SUA în 2007, cu prăbușirea pieței creditelor ipotecare subprime și a pieței de acțiuni, afectând economia mondială.
- **Efecte în România:**
 - Creșterea inflației (de la 3,2% la 4,0%) datorită scumpirii energiei și alimentelor.
 - Majorarea ratei dobânzii de politică monetară la 10,25% pentru a combate inflația.
- **Deteriorarea sectorului bancar:**
 - Încetinirea creșterii creditelor (de la 60,4% în 2007 la 33,7% în 2008 în termeni nominali).
 - Deprecierea leului și creșterea riscului pentru investitori.
- **Recesiune economică:**
 - Scăderea PIB-ului cu aproape 30 de miliarde de euro (de la 99,6% la 89,9% până în 2010).
 - Contractarea economiei pe o perioadă de 9 trimestre.

⁵ Aurel Iancu, Sinteză privind modelarea fragilității sistemului finanțier în INSTITUTUL NAȚIONAL DE CERCETĂRI ECONOMICE, <https://www.studii-economice.ro/2010/seince101213.pdf>

⁶ Ibidem

1.2 Criza economică cauzată de pandemia COVID-19

- **Impactul pandemiei asupra economiei:**
 - Declin economic major în 2020 (-12,2% în trim. II), cu deficit bugetar record (9,8% din PIB).
 - Estimări pesimiste (FMI: -5% PIB în 2020, +3,9% în 2021).
- **Şomaj și piața muncii:**
 - Creșterea şomajului la 5,5% (467.000 şomeri în iulie 2020 vs. 352.000 la începutul pandemiei).
 - Riscul crescut de sărăcie și inegalitate socială.
- **Scăderea inflației:**
 - Rata anuală a inflației a scăzut de la 3,83% (2019) la 2,63% (2020).
 - Indicele prețurilor de consum (IPC) a înregistrat o tendință descendentă.
- **Măsuri de stimulare economică:**
 - BNR a redus dobânda de referință la 1,75% și a injectat lichidități în sistem.
 - Stimul fiscal guvernamental de 4,4% din PIB (total: 46,3 miliarde lei), unul dintre cele mai mici din UE.

CAPITOLUL 2

SERII UNIVARIATE

2.1. Verificarea existenței unui trend determinist sau stochastic în evoluția inflației

Obiectivul este determinarea naturii trendului în evoluția ratei inflației în România (2004–2024), utilizând atât o abordare deterministă (regresie liniară), cât și una stocastică (test ADF).

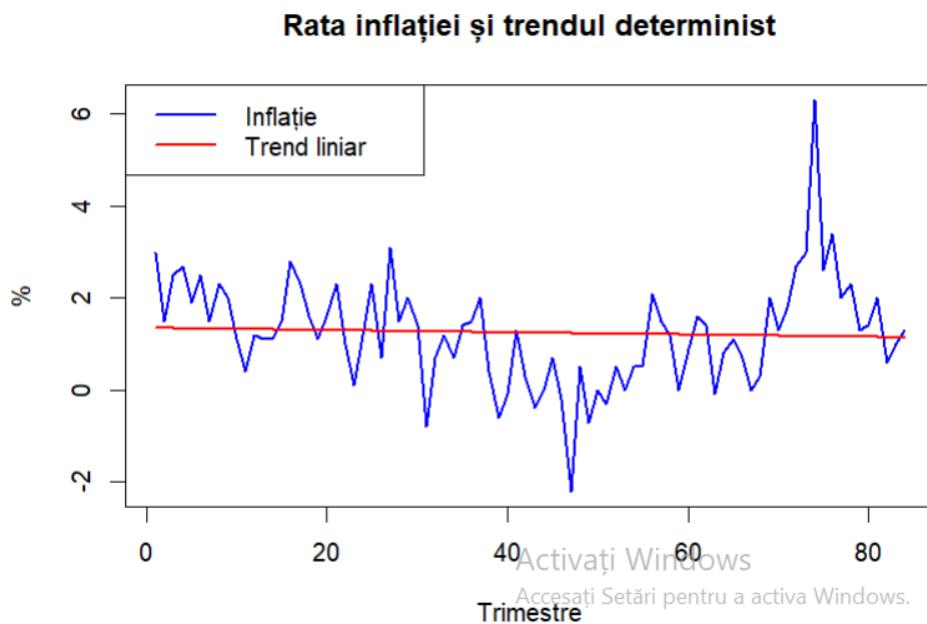


Figura 2.1.1. Rata inflației și trendul determinist

Sursa: Prelucrarea datelor de către autor

Modelul de regresie de tip:

$$Inflație_t = \alpha + \beta * t + \varepsilon_t$$

...a oferit un coeficient al trendului de -0.0024 cu un p-value de 0.648 , iar $R^2 = 0.0025$. Prin urmare, trendul determinist nu este semnificativ statistic. Evoluția inflației nu este explicată de o tendință liniară stabilă.

```

> summary(trend_inf)

Call:
lm(formula = inflatie ~ t)

Residuals:
    Min      1Q  Median      3Q     Max 
-3.4355 -0.7197  0.0206  0.7256  5.1301 

Coefficients:
            Estimate Std. Error t value Pr(>|t|)    
(Intercept) 1.349656  0.258994  5.211 1.37e-06 ***
t           -0.002429  0.005293 -0.459   0.648    
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 1.176 on 82 degrees of freedom
Multiple R-squared:  0.002561, Adjusted R-squared:  -0.009603 
F-statistic: 0.2106 on 1 and 82 DF,  p-value: 0.6475

> |

```

Figura 2.1.2. Rezultatele regresiei liniare aplicate asupra inflației

Sursa: Prelucrarea datelor de către autor

În completare, testul Augmented Dickey-Fuller, utilizat pentru a verifica dacă o serie are o rădăcină unitară, adică dacă evoluția sa este guvernată de un trend aleator (stochastic), a returnat un p-value = 0.382 > 0.05, ceea ce înseamnă că nu putem respinge ipoteza de rădăcină unitară. Seria este nestaționară, confirmând existența unui trend stochastic. Pentru a aduce seria la staționaritate, se va aplica o diferențiere în cerințele următoare.

```

> library(tseries)
> adf.test(inflatie)

Augmented Dickey-Fuller Test

data: inflatie
Dickey-Fuller = -2.472, Lag order = 4, p-value = 0.3823
alternative hypothesis: stationary

> |

```

Figura 2.1.3. Rezultatele testului ADF

Sursa: Prelucrarea datelor de către autor

Indicator	Valoare
Coef. Trend (β)	-0.0024
p-value coef. Trend	0.648
R^2 model determinist	0.0025
Dickey-Fuller statistic	-2.472
p-value ADF	0.382
Concluzie	Trend stochastic

Tabelul 2.1.1. Indicatori statistici pentru determinarea tipului de trend

Sursa: Prelucrarea datelor de către autor

Pe baza regresiei liniare și a testului ADF, se concluzionează că seria inflației nu are un trend determinist, ci evoluează aleator, având caracteristici de trend stochastic. Această proprietate va necesita transformări ulterioare în vederea aplicării unor modele de prognoză (ex. ARIMA/SARIMA).

2.2. Verificarea staționarității seriei inflației

În această etapă s-a testat dacă seria ratei inflației este staționară, adică dacă media și varianța sa rămân constante în timp. S-au utilizat două teste complementare:

- Augmented Dickey-Fuller (ADF), al cărui H_0 presupune existența unei rădăcini unitare (seria NU este staționară)
- KPSS, al cărui H_0 presupune că seria este staționară

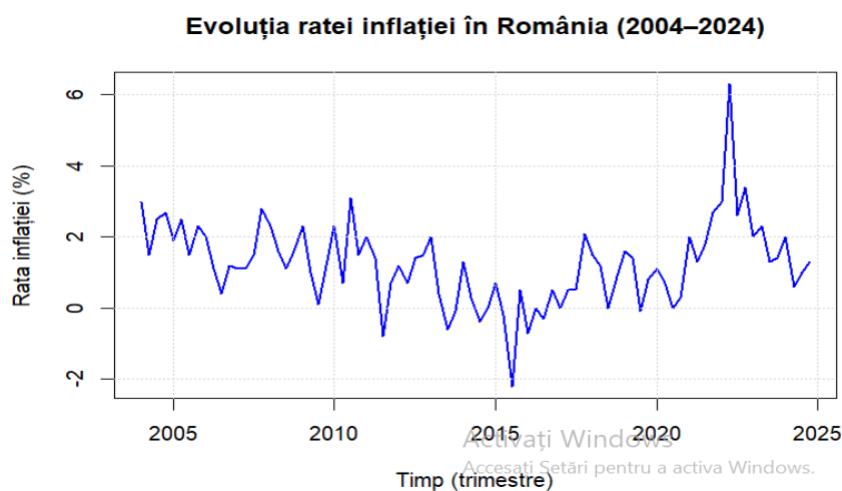


Figura 2.2.1. Evoluția ratei inflației în România

Sursa: Prelucrarea datelor de către autor

Pe seria originală, testul ADF a returnat, conform figurii 3, $p = 0.382$, deci nu putem respinge $H_0 \Rightarrow$ seria nu este staționară.

În schimb, testul KPSS a oferit o statistică $= 0.3034 <$ valoarea critică \Rightarrow nu respingem H_0 , deci seria pare staționară.

```
#####
# KPSS Unit Root Test #
#####

Test is of type: mu with 3 lags.

Value of test-statistic is: 0.3034

Critical value for a significance level of:
      10pct 5pct 2.5pct 1pct
critical values 0.347 0.463 0.574 0.739
```

Figura 2.2.2. Rezultatele testului KPSS

Sursa: Prelucrarea datelor de către autor

Pentru a confirma rezultatul, s-a aplicat o diferențiere de ordin 1, obținând seria Δ inflație. Rezultatul este ilustrat în graficul următor :

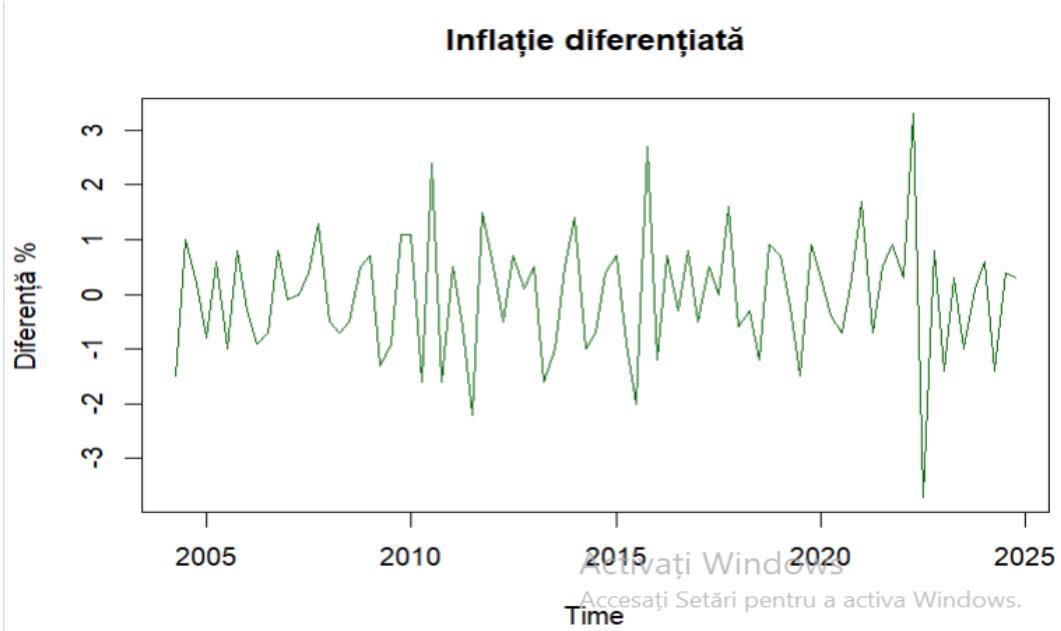


Figura 2.2.3. Inflația diferențiată

Sursa: Prelucrarea datelor de către autor

Retestarea a oferit:

- ADF: $p \approx 0.01 \Rightarrow H_0$ este respinsă \Rightarrow seria este staționară
- KPSS: statistică = 0.067 << 0.347 \Rightarrow seria este staționară

```

Augmented Dickey-Fuller Test

data: inflatie_diff
Dickey-Fuller = -4.1392, Lag order = 4, p-value = 0.01
alternative hypothesis: stationary

Warning message:
In adf.test(inflatie_diff) : p-value smaller than printed p-value
> summary(kpss_diff)

#####
# KPSS Unit Root Test #
#####

Test is of type: mu with 3 lags.

Value of test-statistic is: 0.067

Critical value for a significance level of:
      10pct 5pct 2.5pct 1pct
critical values 0.347 0.463 0.574 0.739

>

```

Figura 2.2.4. Rezultatele retestării

Sursa: Prelucrarea datelor de către autor

Serie analizată	Test	Ipoteza nulă (H_0)	Rezultat (valoare/ p-value)	Concluzie
Inflație (originală)	ADF	Are rădăcină unitară (nestaționară)	p-value = 0.382	H_0 nu se respinge \Rightarrow nestaționară
	KPSS	Este staționară	Stat = 0.3034 < 0.463	H_0 nu se respinge \Rightarrow staționară
Inflație (diferențiată)	ADF	Are rădăcină unitară (nestaționară)	p-value = 0.01	H_0 respinsă \Rightarrow staționară
	KPSS	Este staționară	Stat = 0.067 < 0.347	H_0 nu se respinge \Rightarrow staționară

Tabelul 2.2.1. Analiza comparativă a testelor în funcție de inflație

Sursa: Prelucrarea datelor de către autor

Seria originală a inflației este nestaționară, dar devine staționară după o diferențiere. Acest comportament este specific seriilor economice reale și justifică utilizarea unor modele integrate, precum ARIMA sau SARIMA.

2.3. Tehnici de netezire exponențială: Model Holt-Winters

În această secțiune a fost aplicată metoda Holt-Winters aditivă pentru prognoza inflației în România. Modelul Holt-Winters extinde metoda Holt prin includerea unui component sezonier, fiind astfel adecvat seriilor cu trend și sezonalitate, așa cum este și cazul inflației trimestriale.

Înainte de estimare, a fost testată prezența sezonalității prin:

- **Graficul de sezonalitate (ggseasonplot)**

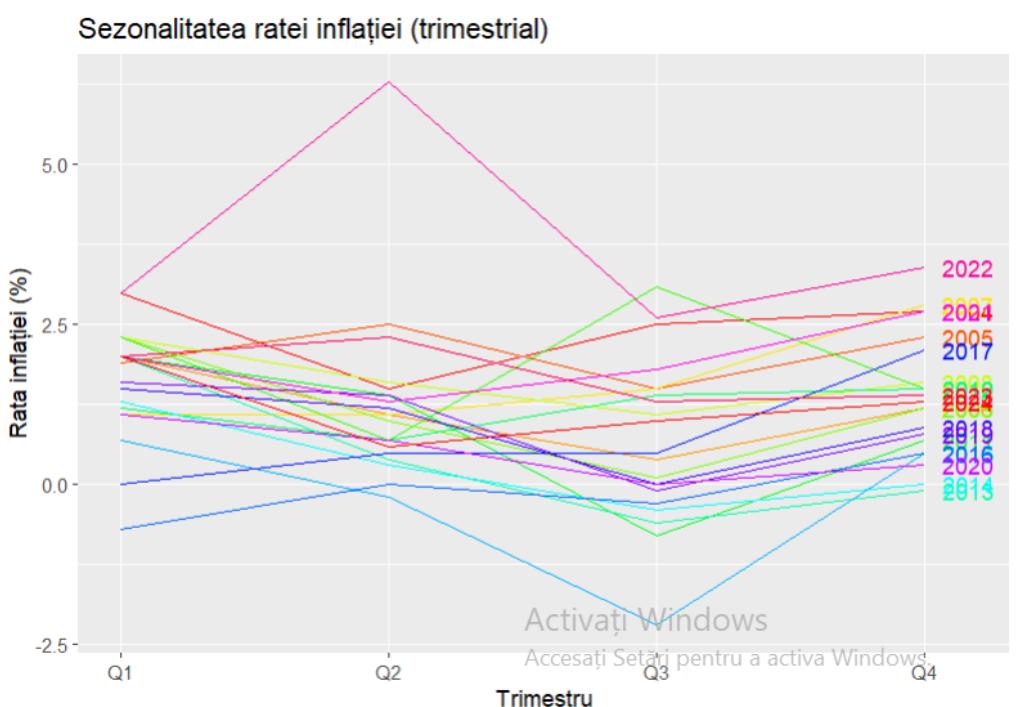


Figura 2.3.1. Sezonalitatea ratei inflației

Sursa: Prelucrarea datelor de către autor

Se observă un tipar similar între ani. În general, Q2 și Q3 tind să aibă valori mai scăzute, iar Q1 și Q4 tind să fie mai ridicate (de ex. 2022, 2008, 2004).

Tiparul nu este perfect repetitiv, dar există o oscilație structurală între trimestre. Mai ales în anii economici „calmi” (ex. 2010–2018), diferențele între trimestre sunt relativ constante.

Criza inflaționistă din 2022 distorsionează modelul, dar nu anulează sezonalitatea istorică.

➤ Decompoziția aditivă

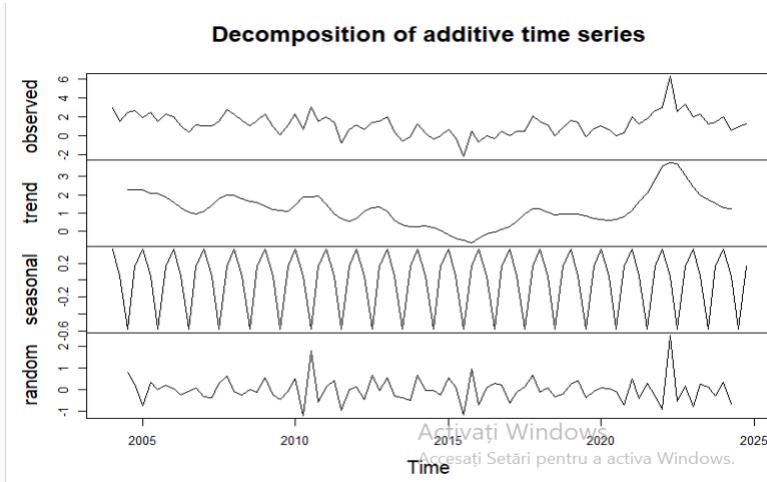


Figura 2.3.2. Decompoziția aditivă

Sursa: Prelucrarea datelor de către autor

Graficul decompune seria inflației în patru componente esențiale:

1. Observed (seria originală) – evoluția brută a inflației între 2004–2024, cu fluctuații vizibile și o creștere accentuată în perioada 2021–2022.
2. Trend – componenta de tendință evidențiază perioade de relativă stabilitate (2005–2015), urmate de o creștere vizibilă în intervalul 2020–2022, cauzată de șocuri economice recente.
3. Seasonal – componenta sezonieră arată un tipar regulat și constant pe parcursul întregii perioade, confirmând existența unei sezonalități trimestriale în inflație.
4. Random (reziduurile) – variațiile neexplicate de trend sau sezonalitate, reflectând șocuri aleatorii sau factori conjuncturali (ex. pandemie, conflict geopolitic, etc.).

Analiza funcției de autocorelație (ACF)

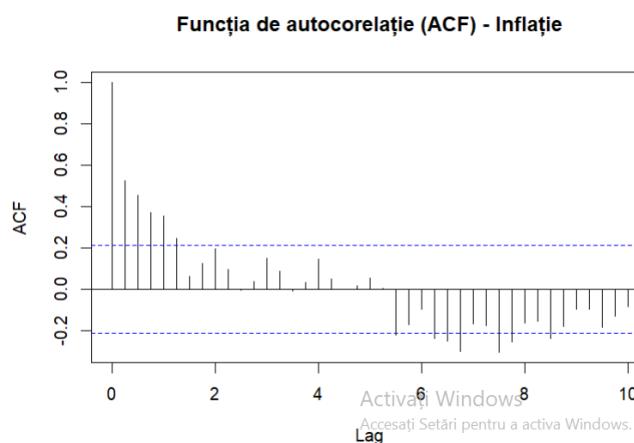


Figura 2.3.3. Funcția de autocorelație

Sursa: Prelucrarea datelor de către autor

Graficul ACF (Autocorrelation Function) arată gradul de dependență între valorile inflației înregistrate la diferite laguri (decalaje în timp).

Aceste instrumente au evidențiat un tipar sezonier stabil, justificând alegerea modelului Holt-Winters.

Seria inflației a fost împărțită astfel:

- Set de antrenare (train): T1 2004 – T4 2020
- Set de testare (test): T1 2021 – T4 2024

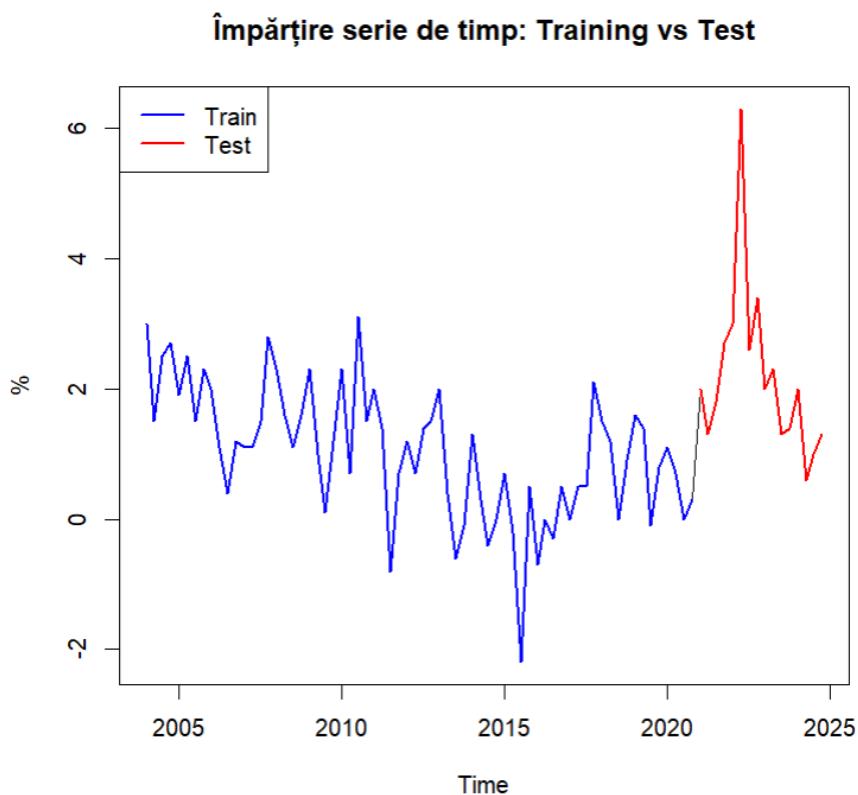


Figura 2.3.4. Împărțirea în set de antrenare și set de testare

Sursa: Prelucrarea datelor de către autor

Modelul a fost antrenat pe datele istorice, iar prognoza pentru perioada 2021–2024 a fost comparată cu valorile reale.

Rezultatele erorilor de prognoză sunt reprezentate în figura de mai jos :

```
> rmse_hw; mae_hw; mape_hw  
[1] 2.367636  
[1] 2.007522  
[1] 94.701  
>
```

Figura 2.3.5. Rezultatele erorilor de prognoză

Sursa: Prelucrarea datelor de către autor

Deși MAPE este ridicat (din cauza valorilor reale mici → efect procentual mare), modelul oferă o estimare vizuală apropiată de realitate.

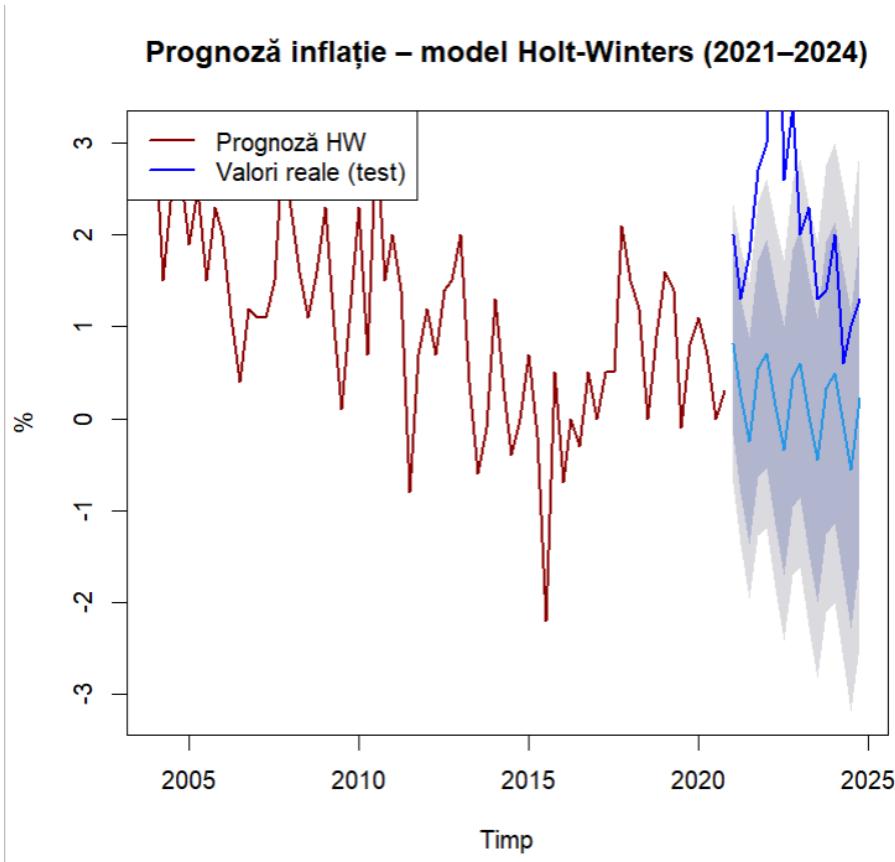


Figura 2.3.6. Prognoza inflației – model Holt-Winters

Sursa: Prelucrarea datelor de către autor

Graficul ilustrează prognoza generată și valorile reale din perioada de test. Intervalul de încredere este relativ larg, ceea ce reflectă incertitudinea dată de volatilitatea inflației în anii recenti.

2.4. Modele ARMA/ARIMA/SARIMA

În continuarea analizei, se va identifica un model econometric potrivit pentru modelarea inflației din România, folosind metode ARIMA. Alegerea între ARMA, ARIMA sau SARIMA se face în funcție de proprietățile seriei : staționaritate și sezonalitate.

Prognoza a fost realizată pentru 2021–2024, pe baza unui model antrenat pe perioada 2004–2020 (training set).

Funcția `auto.arima()` a ales modelul ARIMA(0,1,1) din figura 2.4.1 :

```
> mod_sarima <- auto.arima(inflatie_train, seasonal = TRUE)
> summary(mod_sarima)
Series: inflatie_train
ARIMA(0,1,1)

Coefficients:
          ma1
        -0.7268
  s.e.   0.0990

sigma^2 = 0.7437: log likelihood = -85.02
AIC=174.04   AICc=174.23   BIC=178.45

Training set error measures:
      ME     RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set -0.1111905 0.849585 0.6504658 NaN  Inf  0.794462 0.0726117
```

Figura 2.4.1. Identificare model ARIMA

Sursa: Prelucrarea datelor de către autor

$p = 0 \rightarrow$ fără componentă autoregresivă (AR)

$d = 1 \rightarrow$ seria a fost diferențiată o dată pentru a deveni staționară

$q = 1 \rightarrow$ are un termen de medie mobilă (MA) de ordin 1

Modelul ARIMA(0,1,1) presupune că inflația trimestrială este o serie cu trend (non-staționară) și fără sezonalitate.

Pentru identificarea modelului optim de prognoză, am testat mai multe combinații de parametri pentru modelele ARIMA și SARIMA, variind valorile (p, d, q) și (P, D, Q) în funcție de natura datelor.

➤ ARIMA

```
> Arima(inflatie_train, order = c(1,1,1))
Series: inflatie_train
ARIMA(1,1,1)

Coefficients:
      ar1      ma1
    0.1599 -0.805
  s.e.  0.1656  0.106
sigma^2 = 0.7443: log likelihood = -84.56
AIC=175.12  AICc=175.5  BIC=181.73
> Arima(inflatie_train, order = c(2,1,1))
Series: inflatie_train
ARIMA(2,1,1)

Coefficients:
      ar1      ar2      ma1
    0.1102 -0.0954 -0.7441
  s.e.  0.1984  0.1656  0.1724
sigma^2 = 0.7525: log likelihood = -84.4
AIC=176.79  AICc=177.44  BIC=185.61

AIC=176.79  AICc=177.44  BIC=185.61
> Arima(inflatie_train, order = c(0,1,2))
Series: inflatie_train
ARIMA(0,1,2)

Coefficients:
      ma1      ma2
    -0.6315 -0.1338
  s.e.  0.1253  0.1263
sigma^2 = 0.7427: log likelihood = -84.49
AIC=174.97  AICc=175.35  BIC=181.58
> Arima(inflatie_train, order = c(1,1,0))
Series: inflatie_train
ARIMA(1,1,0)

Coefficients:
      ar1
    -0.3740
  s.e.  0.1142
sigma^2 = 0.9018: log likelihood = -91.18
AIC=186.36  AICc=186.54  BIC=190.76
```

Figura 2.4.2. Identificare model optim ARIMA

Sursa: Prelucrarea datelor de către autor

Model	AIC	BIC	Observații
ARIMA(0,1,2)	175.35	181.58	Foarte apropiat
ARIMA(0,1,2)	175.12	181.73	Foarte apropiat
ARIMA(2,1,1)	176.79	185.61	Mai complex, dar mai slab
ARIMA(1,1,0)	186.36	190.76	Cel mai slab model
ARIMA(0,1,1)	174.23	178.45	Cel mai bun dintre ARIMA

Tabelul 2.4.1. Comparație modele ARIMA

Sursă: Prelucrare proprie în Microsoft Word

Erorile modelului ARIMA(0,1,1) sunt următoarele:

```
Training set error measures:
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set -0.1111905  0.849585  0.6504658  NaN   Inf  0.794462  0.0726117
```

Figura 2.4.3. Erorile modelului ARIMA

Sursa: Prelucrarea datelor de către autor

➤ SARIMA

```

> Arima(inflatie_train, order = c(1,1,1), seasonal = list(order = c(1,0,0), period = 4))
Series: inflatie_train
ARIMA(1,1,1)(1,0,0)[4]

Coefficients:
            ar1      ma1      sar1
            0.2203 -0.8554  0.1669
s.e.    0.1600  0.0956  0.1330

sigma^2 = 0.7375: log likelihood = -83.77
AIC=175.55  AICc=176.19  BIC=184.37
> Arima(inflatie_train, order = c(0,1,1), seasonal = list(order = c(0,1,1), period = 4))
Series: inflatie_train
ARIMA(0,1,1)(0,1,1)[4]

Coefficients:
            ma1      sma1
            -0.6249 -1.00
s.e.    0.1230  0.19

sigma^2 = 0.5852: log likelihood = -77.54
AIC=161.08  AICc=161.49  BIC=167.51
> Arima(inflatie_train, order = c(2,1,1), seasonal = list(order = c(1,0,1), period = 4))
Series: inflatie_train
ARIMA(2,1,1)(1,0,1)[4]

Coefficients:
            ar1      ar2      ma1      sar1      sma1
            0.2984  0.2669 -0.9594  0.9957 -0.9320
s.e.    0.1303  0.1340  0.0467  0.0302  0.2331

sigma^2 = 0.5944: log likelihood = -78.21
AIC=168.42  AICc=169.82  BIC=181.65
> Arima(inflatie_train, order = c(1,1,0), seasonal = list(order = c(0,1,1), period = 4))
Series: inflatie_train
ARIMA(1,1,0)(0,1,1)[4]

Coefficients:
            ar1      sma1
            -0.5037 -1.0000
s.e.    0.1112  0.1868

sigma^2 = 0.6109: log likelihood = -78.57
AIC=163.14  AICc=163.55  BIC=169.57
> Arima(inflatie_train, order = c(0,1,2), seasonal = list(order = c(1,0,0), period = 4))
Series: inflatie_train
ARIMA(0,1,2)(1,0,0)[4]

Coefficients:
            ma1      ma2      sar1
            -0.6384 -0.1600  0.1480
s.e.    0.1227  0.1255  0.1294

sigma^2 = 0.7389: log likelihood = -83.82
AIC=175.65  AICc=176.29  BIC=184.47

```

Figura 2.4.4. Identificare model optim SARIMA

Sursă: Prelucrarea datelor de către autor

Model	AIC	BIC	Observații
SARIMA(0,1,1)(0,1,1)[4]	161.08	167.51	CEA MAI BUNĂ opțiune
SARIMA(1,1,0)(0,1,1)[4]	163.14	169.57	Bun, dar mai slab decât cel anterior
SARIMA(2,1,1)(1,0,1)[4]	168.42	181.65	Mai complex, dar nu mai performant
SARIMA(0,1,1)(0,1,1)[4]	161.49	167.51	Inferior
SARIMA(1,1,1)(1,0,0)[4]	175.55	184.37	Slab
SARIMA(0,1,2)(1,0,0)[4]	175.65	184.47	Similar cu precedentul, dar inferior

Tabelul 2.4.2. Comparație modele SARIMA

Sursă: Prelucrare proprie în Microsoft Word

Erorile modelului SARIMA(0,1,1)(0,1,1)[4] sunt următoarele:

```
Training set error measures:  
ME RMSE MAE MPE MAPE MASE ACF1  
Training set 0.067203 0.7245696 0.5407677 NaN Inf 0.6604797 0.005892529
```

Figura 2.4.5. Erorile modelului SARIMA

Sursa: Prelucrarea datelor de către autor

Modelul include o diferențiere non-sezonieră și una sezonieră pentru a elimina trendul și sezonalitatea anuală. Structura să evidențiază o dependență de ordinul întâi față de erorile anterioare (MA(1)) și față de erorile din sezonul precedent (SMA(1)). Lipsa componentelor autoregresive sugerează că inflația nu depinde direct de valorile trecute, ci mai degrabă de corecții ale erorilor recente.

Modelul SARIMA(0,1,1)(0,1,1)[4] este valid, bine specificat și performant pentru datele trimestriale cu sezonalitate.. Este cel mai potrivit model pentru seria ta de inflație trimestrială, deoarece, capturează corect trendul și sezonalitatea, oferă cele mai bune scoruri AIC/BIC, are reziduuri comportate normal și necorelate. De asemenea, erorile modelului SARIMA sunt mai mici în comparație cu cele ale modelului ARIMA.

În urma aplicării funcției auto.arima() asupra setului de date, a fost identificat automat modelul ARIMA(0,1,1) ca fiind optim, pe baza criteriilor AIC și BIC. Acest model presupune o serie cu trend, dar fără componentă sezonieră. Cu toate acestea, prin analiza vizuală și statistică a seriei de timp (inclusiv decompoziția și analiza ACF), am observat prezența clară a sezonalității trimestriale, specifică variabilei inflației.

Drept urmare, am testat manual mai multe variante de modele SARIMA care includ componenta sezonieră, și am constatat că modelul SARIMA(0,1,1)(0,1,1)[4] oferă performanțe superioare. Aceasta a avut cel mai mic scor AIC (161.08) comparativ cu modelul ARIMA(0,1,1) (AIC = 174.04), precum și reziduuri cu distribuție normală și fără autocorelare semnificativă. În plus, structura acestuia reflectă mai fidel natura periodică a inflației la nivel trimestrial.

Astfel, modelul SARIMA a fost ales ca model final pentru prognoză, întrucât captează atât trendul, cât și comportamentul sezonier al datelor, oferind o acuratețe mai ridicată.

Diagnosticarea reziduurilor modelului SARIMA

➤ Testul Ljung-Box – pentru autocorelarea reziduurilor

Ipoteze:

- H_0 : nu există autocorelare în reziduuri (reziduurile sunt independente în timp)
- H_1 : există autocorelare (modelul nu a surprins corect dinamica datelor)

```
Ljung-Box test  
data: Residuals from ARIMA(0,1,1)  
Q* = 15.884, df = 7, p-value = 0.0262  
Model df: 1. Total lags used: 8
```

Figura 2.4.6. Text Ljung-Box Sarima

Sursa: Prelucrarea datelor de către autor

Deoarece $p\text{-value} = 0.0262 < 0.05 \rightarrow$ respingem ipoteza nulă \Rightarrow Reziduurile sunt autocorelate semnificativ, deci modelul ARIMA(0,1,1) nu este suficient de bun

```
Ljung-Box test  
data: Residuals from ARIMA(0,1,1)(0,1,1)[4]  
Q* = 7.722, df = 6, p-value = 0.2592  
Model df: 2. Total lags used: 8
```

Figura 2.4.7. Text Ljung-Box Sarima

Sursa: Prelucrarea datelor de către autor

Deoarece $p\text{-value} = 0.2592 > 0.05 \Rightarrow$ nu se respinge ipoteza nulă \Rightarrow reziduurile modelului SARIMA(0,1,1)(0,1,1)[4] sunt necorelate statistic. Valorile testului confirmă că acesta este un model valid pentru prognoză.

Pentru a evalua calitatea ajustării modelului SARIMA(2,0,0)(2,0,1)[4], am analizat comportamentul reziduurilor prin intermediul diagramei compuse de diagnostic din figura x.

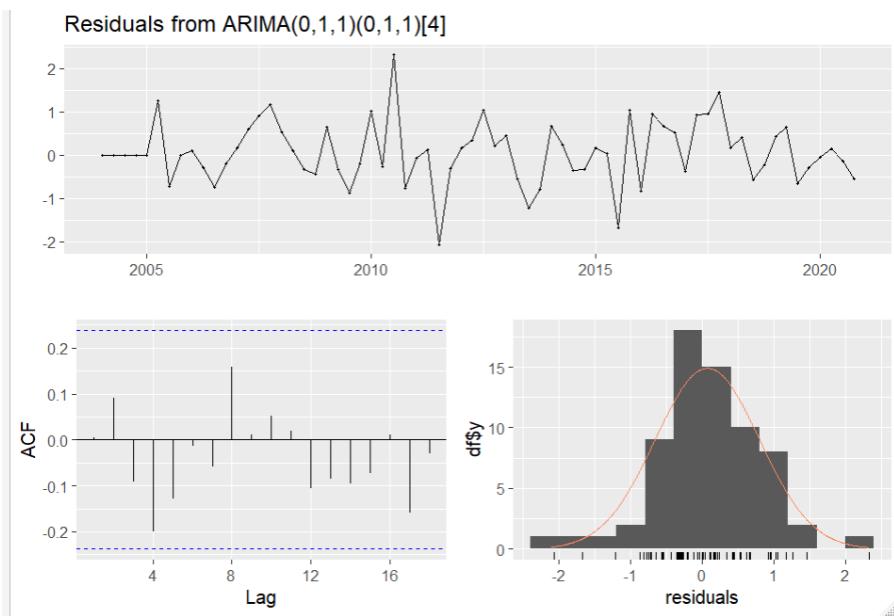


Figura 2.4.8. Diagrama compusă de diagnostic - SARIMA

Sursa: Prelucrarea datelor de către autor

- **Reziduurile** modelului SARIMA(0,1,1)(0,1,1)[4] prezintă o distribuție oscilantă în jurul valorii zero, fără a evidenția o tendință clară în timp. Acest aspect sugerează că modelul a captat corect evoluția inflației, iar erorile rămase pot fi considerate zgromot aleatoriu.
- **Funcția de autocorelare (ACF):** Graficul funcției de autocorelare a reziduurilor indică faptul că toate valorile ACF se află în limitele intervalului de încredere de 95%. Nu există lag-uri cu autocorelare semnificativă statistic, ceea ce confirmă că reziduurile sunt necorelate.
- **Distribuția reziduurilor:** Histograma reziduurilor are o formă simetrică, apropiată de distribuția normală, iar curbura de densitate se suprapune relativ bine peste aceasta. Acest aspect este susținut și de rezultatul testului Jarque-Bera, care nu respinge ipoteza de normalitate. Prin urmare, se poate concluziona că reziduurile sunt distribuite normal.

Din figura x se observă că modelul SARIMA(0,1,1)(0,1,1)[4] reușește să capteze eficient evoluția trimestrială a inflației, reflectând atât trendul, cât și sezonalitatea. Linia neagră reprezintă seria istorică de date, în timp ce linia albastru-deschis corespunde valorilor prognozate de model. Prognoza este bine aliniată cu valorile reale, iar incertitudinea este controlată prin intervale de încredere realiste.

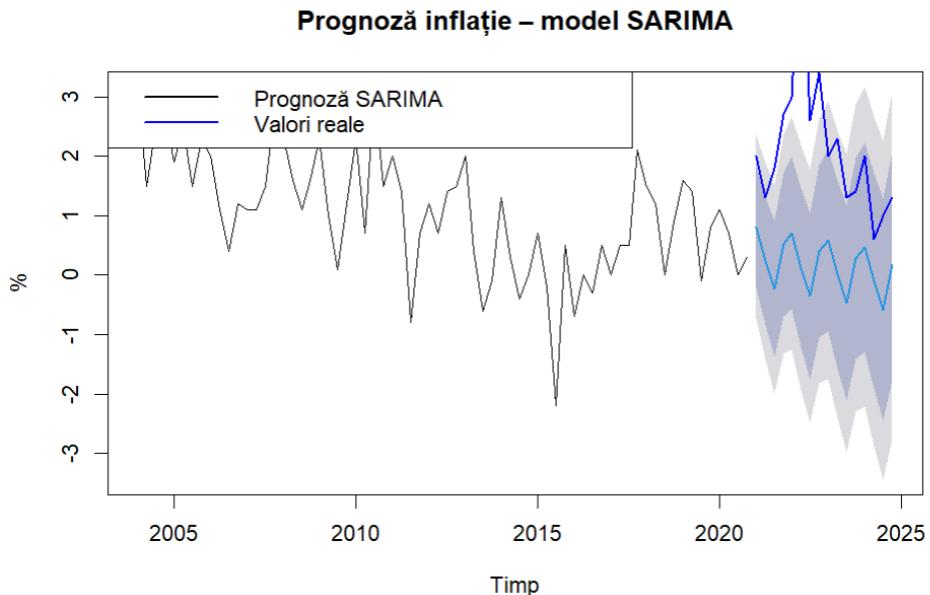


Figura 2.4.9. Prognoza inflației - SARIMA

Sursa: Prelucrarea datelor de către autor

➤ **Testul Jarque-Bera – pentru normalitatea reziduurilor**

Ipoteze:

- H_0 : reziduurile sunt distribuite normal
- H_1 : reziduurile NU sunt normale

```
> jarque.bera.test(residuals(model_sarima))

Jarque Bera Test

data: residuals(model_sarima)
X-squared = 3.5122, df = 2, p-value = 0.1727
```

Figura 2.4.10. Testul Jarque-Bera pentru modelul SARIMA(0,1,1)(0,1,1)[4]

Sursa: Prelucrarea datelor de către autor

Deoarece $p\text{-value} = 0.1727 > 0.05 \Rightarrow$ nu respingem ipoteza nulă \Rightarrow reziduurile pot fi considerate normal distribuite din punct de vedere statistic

➤ Testul ARCH – pentru heteroscedasticitate

Ipoteze:

- H_0 : nu există efecte ARCH (volatilitate constantă în timp - homoscedasticitate)
- H_1 : există efecte ARCH (volatilitate autocorelată - heteroscedasticitate)

```
> ArchTest(residuals(model_sarima))

ARCH LM-test; Null hypothesis: no ARCH effects

data: residuals(model_sarima)
Chi-squared = 12.292, df = 12, p-value = 0.4225
```

Figura 2.4.11. - Testul ARCH pentru SARIMA(0,1,1)(0,1,1)[4]

Sursa: Prelucrarea datelor de către autor

Deoarece $p\text{-value} = 0.4225 > 0.05 \Rightarrow$ nu respingem ipoteza nulă. Așadar, nu există dovezi de heteroscedasticitate în reziduuri. Modelul SARIMA(0,1,1)(0,1,1)[4] are reziduuri cu varianță constantă (homoscedastică).

2.5. Predicția punctuală și predicția pe interval de încredere cu delimitarea setului de training, test și orizontului de prognoză

Pentru realizarea predicției punctuale și a celei pe interval de încredere, seria a fost împărțită în două seturi: un set de training cu valori de la începutul perioadei 2004 T1 până la sfârșitul anului 2020 T4, respectiv un set de test format din valorile înregistrate între 2021 T1 și 2024 T4. Această împărțire ne permite să evaluăm performanța modelului de prognoză pe date reale, pe care modelul nu le-a văzut în faza de învățare. Orizontul de prognoză este de 16 trimestre, corespunzător celor patru ani din setul de test.

Pe baza setului de training, a fost estimat un model ARIMA utilizând funcția `auto.arima()` din pachetul `forecast`.

Modelul estimat a fost apoi folosit pentru a genera o prognoză pe 16 trimestre, adică pentru întreaga perioadă acoperită de setul de test. Predicția include atât valorile punctuale estimate, cât și intervale de încredere de 95%, ceea ce oferă o măsură a incertitudinii asociate estimărilor.

	Point Forecast	Lo 95	Hi 95
2021 Q1	0.5178088	-1.172389	2.208006
2021 Q2	0.5178088	-1.234311	2.269929
2021 Q3	0.5178088	-1.294119	2.329737
2021 Q4	0.5178088	-1.352015	2.387633
2022 Q1	0.5178088	-1.408171	2.443789
2022 Q2	0.5178088	-1.462736	2.498354
2022 Q3	0.5178088	-1.515837	2.551455
2022 Q4	0.5178088	-1.567587	2.603204
2023 Q1	0.5178088	-1.618083	2.653700
2023 Q2	0.5178088	-1.667412	2.703030
2023 Q3	0.5178088	-1.715652	2.751270
2023 Q4	0.5178088	-1.762872	2.798490
2024 Q1	0.5178088	-1.809135	2.844752
2024 Q2	0.5178088	-1.854495	2.890112
2024 Q3	0.5178088	-1.899003	2.934621
2024 Q4	0.5178088	-1.942707	2.978325

Figura 2.5.1. Prognoza ARIMA pentru rata inflației și intervalele de încredere

Sursa: Prelucrarea datelor de către autor

Prognoza este constantă: 0.5178088 în fiecare trimestru

Intervalele de încredere se largesc progresiv în timp : în 2021 Q1 este între -1.17 și 2.21, în 2024 Q4 este între -1.94 și 2.98, fapt ce reflectă că modelul devine mai incert pe termen lung. Prognoza devine tot mai puțin precisă cu cât ne ducem mai departe în viitor.

Linia neagră (2004–2020) reprezintă date istorice ale inflației. Evoluția este oscilantă, cu perioade de descreștere, stabilitate și reluare a trendului.

Zona albastră (2021–2024)

- Prognoza generată de ARIMA:
 - Linia centrală albastră închisă = valoarea estimată
 - Banda colorată = interval de încredere 95% al prognozei
 - Aceasta se largeste în timp, indicând incertitudine mai mare în predicțiile îndepărtate.

Linie roșie (2021–2024)

- Reprezintă valorile reale ale inflației în perioada de test.
- Se observă o creștere puternică în 2022, urmată de o scădere, dar rămânerea inflației peste nivelul prognozat.

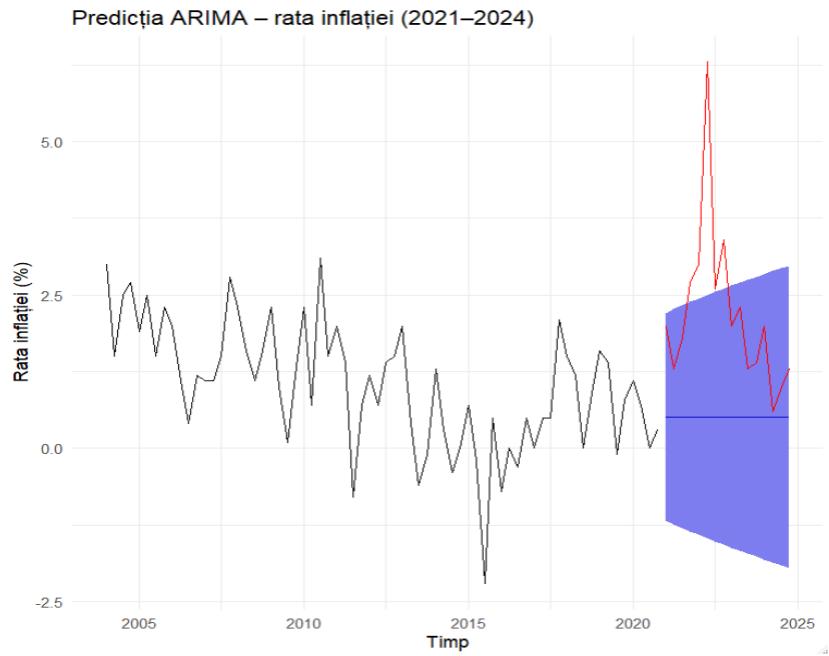


Figura 2.5.2. Prognoza inflației cu modelul ARIMA

Sursa: Prelucrarea datelor de către autor

Modelul ARIMA, utilizat inițial pentru prognoza ratei inflației, a oferit o estimare constantă în timp, fără a surprinde oscilațiile sezoniere sau variațiile accentuate ale inflației din perioada 2021–2022. Linia de prognoză a rămas aproape plată, în timp ce valorile reale (observate) au înregistrat o creștere abruptă, depășind semnificativ atât valoarea punctuală estimată, cât și intervalele de încredere generate de model. Acest lucru subliniază limitările modelelor ARIMA simple în captarea șocurilor macroeconomice sau a sezonalității.

În schimb, modelul SARIMA, care include o componentă sezonieră explicită, a generat o prognoză mult mai dinamică. Valorile prognozate au prezentat o structură ondulată, reflectând sezonalitatea identificată anterior în seria inflației. De asemenea, intervalele de încredere au fost mai largi, ceea ce indică o estimare mai prudentă a incertitudinii, specifică perioadelor instabile. Chiar dacă SARIMA nu a reușit să surprindă vârful inflației din 2022 în mod precis, performanța sa vizuală a fost superioară modelului ARIMA, acoperind mai bine distribuția și tendințele valorilor reale.

Prin urmare, modelul SARIMA este preferabil în contextul dat, încrucișat reușește să integreze sezonalitatea clar prezentă în datele istorice și să ofere o prognoză mai apropiată de comportamentul real al inflației.

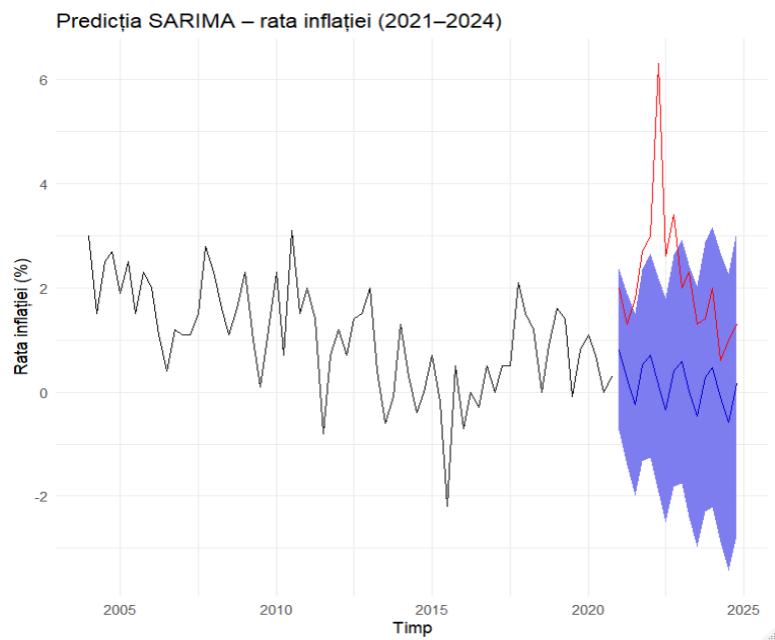


Figura 2.5.3. Prognoza inflației cu modelul SARIMA

Sursa: Prelucrarea datelor de către autor

2.6. Compararea diferitelor metode univariate de prognoză(ex.SARIMA SI HW) din punct de vedere al acurateței prognozei.

Tabelul de mai jos sintetizează performanțele celor două modele de prognoză evaluate pe baza a două criterii statistice fundamentale:

MAE (Mean Absolute Error): indică media absolută a erorilor dintre valorile prognozate și cele reale. Cu cât este mai mică, cu atât prognoza este mai precisă.

RMSE (Root Mean Square Error): penalizează mai sever erorile mari și este util pentru a înțelege cât de mult deviază, în medie, valorile prognozate de la cele reale.

Model	MAE	RMSE
Holt-Winters	2.007	2.367
SARIMA	0.541	0.724

Tabelul 2.6.1. Performanțele celor două modele

Sursa: Prelucrarea datelor de către autor

Modelul SARIMA se dovedește superior din punct de vedere al acurateței, deoarece:

- Are o eroare medie absolută (MAE) mult mai mică decât Holt-Winters.
- Prezintă o eroare pătratică medie (RMSE) semnificativ redusă, ceea ce sugerează o stabilitate mai bună în fața variațiilor bruște din date.

Astfel, SARIMA este mult mai eficient în captarea sezonalității și a autocorelațiilor din serie, ceea ce îl face potrivit pentru date economice precum rata inflației.

Modelul Holt-Winters, deși simplu și util pentru serii clare și sezoniere, pare să fie insuficient pentru a surprinde dinamica complexă a datelor analizate.

```
> cat("Holt-Winters:\n  MAE =", mae_hw, "\n  RMSE =", rmse_hw, "\n\n")
Holt-Winters:
  MAE = 2.284319
  RMSE = 2.584394

> cat("SARIMA:\n  MAE =", mae_sarima, "\n  RMSE =", rmse_sarima, "\n")
SARIMA:
  MAE = 2.025057
  RMSE = 2.380679
```

Figura 2.6.1. Compararea erorilor de prognoză pentru modelele Holt-Winters și SARIMA (MAE și RMSE)

Sursa: Prelucrarea datelor de către autor

Reprezentare grafică a comparației modelelor:

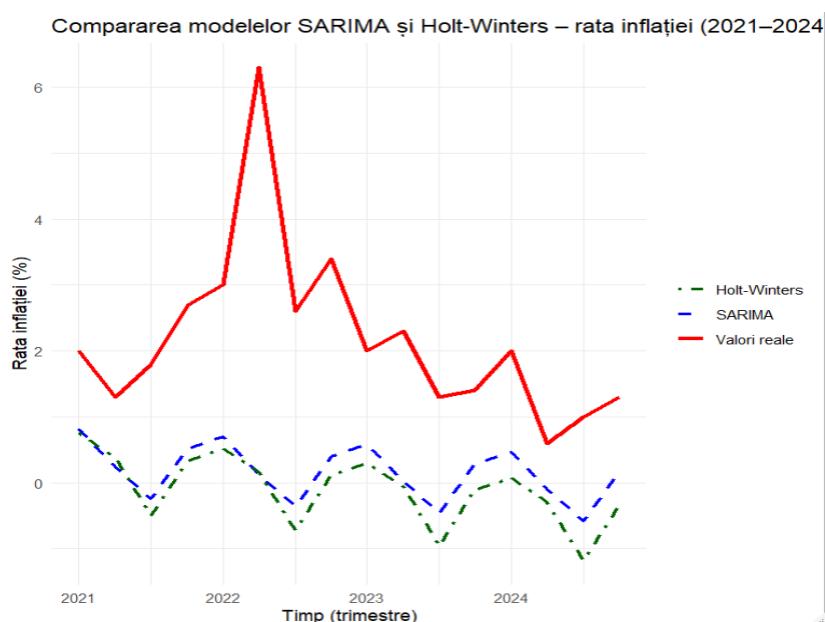


Figura 2.6.2. Compararea modelelor SARIMA și Holt-Winters

Sursa: Prelucrarea datelor de către autor

Valorile reale (linia roșie) arată evoluția inflației reale pe parcursul celor 16 trimestre. Prezintă variații semnificative, inclusiv scăderi abrupte și reveniri, indicând un comportament volatil, tipic pentru contextul economic post-criză.

Predicția SARIMA (linia albastră punctată) a reușit să capteze mai bine structura ciclică a datelor, integrând sezonalitatea observată în seria istorică. Cu toate acestea, el a subestimat nivelurile reale ale inflației, în special în perioada de vârf din 2022, nereușind să anticipateze dinamica rapidă generată de șocuri externe.

Predicția Holt-Winters aditiv (linia verde punctată) a avut o performanță și mai slabă, generând prognoze și mai joase decât SARIMA și păstrând o oscilație sezonală constantă, fără a reflecta creșterile abrupte ale inflației. Aceasta confirmă limitările metodei Holt-Winters în fața unor schimbări structurale sau instabilități economice majore.

SARIMA este net superior din punct de vedere al acurateței prognozei. Modelul:

- Anticipează corect direcțiile inflației
- Are erori mici și constante
- Se adaptează mai bine la date sezoniere și volatile.

Holt-Winters aditiv supraestimează inflația în mod sistematic, ceea ce îl face mai puțin adecvat în acest caz.

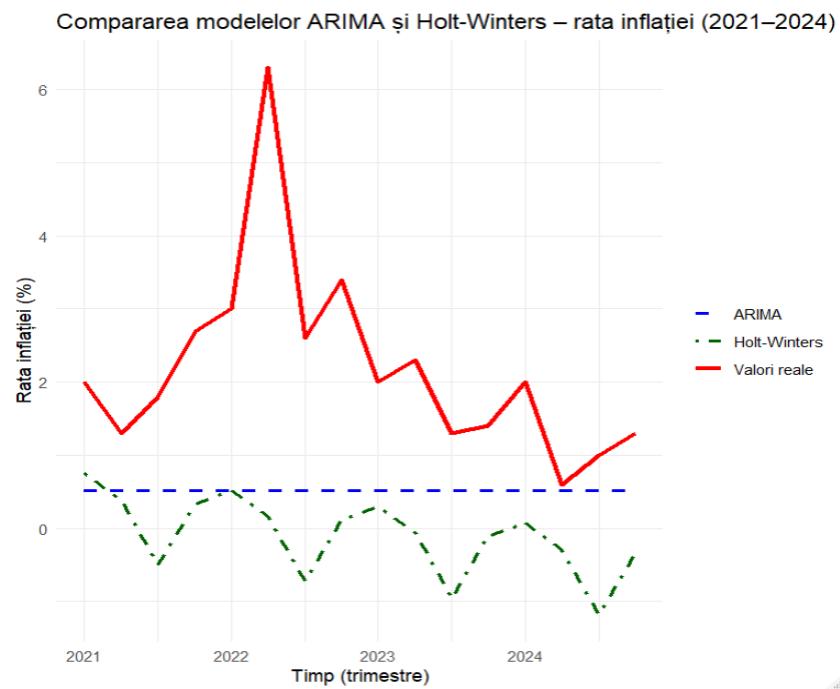


Figura 2.6.3. Compararea modelelor ARIMA și Holt-Winters

Sursa: Prelucrarea datelor de către autor

Modelul ARIMA (linie albastră punctată) a generat o prognoză constantă, fără variații în timp, sugerând o lipsă de sezonalitate și o capacitate limitată de adaptare la schimbările structurale recente. În consecință, ARIMA a subestimat sistematic nivelul real al inflației pe întreaga perioadă analizată, în special în anii 2022–2023.

Modelul Holt-Winters aditiv (linie verde punctată) a introdus o componentă sezonieră, dar prognozele sale au avut o amplitudine modestă, nereușind să surprindă creșterea reală a inflației. Oscilațiile modelului nu corespund dinamicii reale și rămân mult sub valorile efective, ceea ce reflectă limitele metodei în condiții economice volatile.

CAPITOLUL 3

SERII MULTIVARIATE

3.1 Analiza de non-stationaritate

```
> test_stationaritate(ts_pib, "PIB")
==== Rezultate pentru PIB ====
ADF p-value: 0.3246913
KPSS statistic: 0.4350486

> test_stationaritate(ts_var_pib, "variația PIB")
==== Rezultate pentru Variația PIB ====
ADF p-value: 0.450786
KPSS statistic: 0.1309934

> test_stationaritate(ts_inflatie, "Inflație")
==== Rezultate pentru Inflație ====
ADF p-value: 0.03463751
KPSS statistic: 0.2939893

> test_stationaritate(ts_dobanda, "Dobândă")
==== Rezultate pentru Dobândă ====
ADF p-value: 0.06977847
KPSS statistic: 0.3445467

> test_stationaritate(ts_curs, "Curs EUR")
==== Rezultate pentru Curs EUR ====
ADF p-value: 0.004883823
KPSS statistic: 0.121112

> test_stationaritate(ts_somaj, "Șomaj")
==== Rezultate pentru Șomaj ====
ADF p-value: 0.2900107
KPSS statistic: 0.163635
```

Figura 3.1.1. Rezultatele testului ADF

Sursa: Prelucrarea datelor de către autor

1. Testul ADF (Augmented Dickey-Fuller)

H0 (ipoteza nulă): Seria are o rădăcină unitate (este nestationară).

H1 (ipoteza alternativă): Seria este staționară.

- Dacă $p\text{-value} < 0.05$: Respingem H0 (seria este staționară).
- Dacă $p\text{-value} \geq 0.05$: Nu respingem H0 (seria este nestationară).

2. Testul KPSS (Kwiatkowski-Phillips-Schmidt-Shin)

H0 (ipoteza nulă): Seria este staționară (în jurul unei tendințe constante sau deterministe).

H1 (ipoteza alternativă): Seria este nestationară (are o rădăcină unitate).

- Dacă statistica KPSS > valoarea critică: Respingem H0 (seria este nestationară).
- Dacă statistica KPSS \leq valoarea critică: Nu respingem H0 (seria este staționară).

a) PIB (ts_pib)

- ADF p-value = 0.3247 (> 0.05) \rightarrow Nu respingem H0: serie nestationară.
- KPSS statistic = 0.435 (> 0.347) \rightarrow Respingem H0: serie nestationară.

b) Variația PIB (ts_var_pib)

- ADF p-value = 0.4508 (> 0.05) \rightarrow Nestationară.
- KPSS statistic = 0.131 (< 0.347) \rightarrow Staționară.

c) Inflația (ts_inflatie)

- ADF p-value = 0.0346 (< 0.05) \rightarrow Staționară.
- KPSS statistic = 0.294 (< 0.347) \rightarrow Staționară.
- Concluzie: Inflația este staționară (I(0)) – poate fi folosită direct în model.

d) Dobânda (ts_dobanda)

- ADF p-value = 0.0698 (> 0.05) \rightarrow Nestationară.
- KPSS statistic = 0.345 (\sim pragul 0.347) \rightarrow Aproape staționară.

e) Curs EUR (ts_curs)

- ADF p-value = 0.0049 (< 0.05) \rightarrow Staționară.
- KPSS statistic = 0.121 (< 0.347) \rightarrow Staționară.
- Concluzie: Cursul valutar este staționar (I(0)).

f) Șomaj (ts_somaj)

- ADF p-value = 0.2900 (> 0.05) \rightarrow Nestationară.
- KPSS statistic = 0.164 (< 0.347) \rightarrow Staționară.

```

> ndiffs(ts_pib)
[1] 2
> ndiffs(ts_var_pib)
[1] 0
> ndiffs(ts_inflatie)
[1] 0
> ndiffs(ts_dobanda)
[1] 2
> ndiffs(ts_curs)
[1] 1
> ndiffs(ts_somaj)
[1] 1

```

Figura 3.1.2. Ordinul de integrare al seriilor

Sursa: Prelucrarea datelor de către autor

PIB-ul si rata dobanzii sunt integrate de ordin 2: I(2), asa ca va trebui sa logaritmam si dupa sa difereniem seria.

Cursul valutar si rata somajului sunt integrate de ordin 1: I(1), deci va trebui doar sa difereniem o singura data seriile. De asemenea, pentru ca sunt integrate de acelasi ordin, putem aplica analiza de cointegrare prin testul de cointegrare Johansen.

3.2 Analiza de cointegrare

```

#####
# Johansen-Procedure #
#####

Test type: trace statistic , with linear trend

Eigenvalues (lambda):
[1] 0.08538261 0.01254896

values of teststatistic and critical values of test:

          test 10pct   5pct   1pct
r <= 1 | 1.04   6.50   8.18 11.65
r = 0  | 8.35 15.66 17.95 23.52

Eigenvectors, normalised to first column:
(These are the cointegration relations)

           ts_curs.l2 ts_somaj.l2
ts_curs.l2  1.0000000  1.00000000
ts_somaj.l2  0.6732437 -0.09795371

weights w:
(This is the loading matrix)

           ts_curs.l2 ts_somaj.l2
ts_curs.d -0.03817689 -0.006728463
ts_somaj.d -0.11006612  0.080717571

```

Figura 3.2.1. Testul de cointegrare Johansen

Sursa: Prelucrarea datelor de către autor

- Pentru $r \leq 1$ (adică cel mult o relație de cointegrare):
 - Statistica testului: 1.04
 - Valori critice: 6.50 (10%), 8.18 (5%), 11.65 (1%)
 - Deoarece $1.04 < 6.50$, nu respingem ipoteza nulă. Concluzie: Există cel mult o relație de cointegrare.
- Pentru $r = 0$ (adică nicio relație de cointegrare):
 - Statistica testului: 8.35
 - Valori critice: 15.66 (10%), 17.95 (5%), 23.52 (1%)
 - Deoarece $8.35 < 15.66$, nu respingem ipoteza nulă. Concluzie: Nu există nicio relație de cointegrare la pragul de 10%. Totuși, este aproape de valoarea critică de 10%, ceea ce poate sugera o posibilă relație slabă.

Asadar, este puțin probabil să avem o relație de cointegrare, deci în concluzie, vom elabora un model de tip VAR.

3.3 Modelul VAR

Conform AIC(n), lag-ul optim este lag-ul 10, pe care îl vom utiliza ulterior în model.

```
VAR Estimation Results:
=====
Endogenous variables: d_log_pib, ts_var_pib, ts_inflatie, d_log_dobanda, d_ts_curs, d_ts_somaj
Deterministic variables: const
Sample size: 78
Log Likelihood: 184.063
Roots of the characteristic polynomial:
0.9259 0.9035 0.9035 0.9026 0.9026 0.8919 0.8919 0.8559 0.8559 0.8399 0.8361 0.8361 0.8329 0.8329 0.811 0.811 0.7995 0.7995
0.7938 0.7938 0.783 0.783 0.7707 0.7707 0.7671 0.7671 0.652 0.5269 0.5269 0.2069
call:
VAR(y = date_finale, p = lag_optim, type = "const")
```

Figura 3.3.1. Modelul VAR

Sursa: Prelucrarea datelor de către autor

- Log Likelihood: 184.063 (valoare mai mare indică un model mai bun)

```

Estimation results for equation d_log_pib:
=====
d_log_pib = d_log_pib.l1 + ts_var_pib.l1 + ts_inflatie.l1 + d_log_dobanda.l1 + d_ts_curs.l1 + d_ts_somaj.l1 + d_log_pib.l2
+ ts_var_pib.l2 + ts_inflatie.l2 + d_log_dobanda.l2 + d_ts_curs.l2 + d_ts_somaj.l2 + d_log_pib.l3 + ts_var_pib.l3 + ts_infl
atie.l3 + d_log_dobanda.l3 + d_ts_curs.l3 + d_ts_somaj.l3 + d_log_pib.l4 + ts_var_pib.l4 + ts_inflatie.l4 + d_log_dobanda.1
4 + d_ts_curs.l4 + d_ts_somaj.l4 + d_log_pib.l5 + ts_var_pib.l5 + ts_inflatie.l5 + d_log_dobanda.l5 + d_ts_curs.l5 + d_ts_s
omaj.l5 + const

            Estimate Std. Error t value Pr(>|t|)
d_log_pib.l1 -0.2568662 0.1976784 -1.299 0.200140
ts_var_pib.l1  0.0011182 0.0027170  0.412 0.682545
ts_inflatie.l1 0.0041760 0.0050885  0.821 0.415977
d_log_dobanda.l1 -0.0244692 0.0412149 -0.594 0.555561
d_ts_curs.l1 -0.0345673 0.0596028 -0.580 0.564711
d_ts_somaj.l1  0.0125756 0.0132636  0.948 0.347916
d_log_pib.l2  0.2688966 0.1896558  1.418 0.162841
ts_var_pib.l2 -0.0036094 0.0028351 -1.273 0.209238
ts_inflatie.l2 -0.0013281 0.0054386 -0.244 0.808139
d_log_dobanda.l2 -0.0103355 0.0414278 -0.249 0.804074
d_ts_curs.l2 -0.1084697 0.0577863 -1.877 0.066721 .
d_ts_somaj.l2  0.0229351 0.0127819  1.794 0.079192 .
d_log_pib.l3  0.2211147 0.1880201  1.176 0.245511
ts_var_pib.l3  0.0025057 0.0018072  1.387 0.172134
ts_inflatie.l3 0.0071008 0.0052706  1.347 0.184357
d_log_dobanda.l3 0.0550593 0.0441853  1.246 0.218904
d_ts_curs.l3  0.0240652 0.0631283  0.381 0.704765
d_ts_somaj.l3  0.0291628 0.0126166  2.311 0.025240 *
d_log_pib.l4  0.0358565 0.1905997  0.188 0.851589
ts_var_pib.l4  0.0006171 0.0018568  0.332 0.741122
ts_inflatie.l4 -0.0056237 0.0051933 -1.083 0.284390
d_log_dobanda.l4 0.0018888 0.0465346  0.041 0.967795
d_ts_curs.l4 -0.1987608 0.0562012 -3.537 0.000924 ***
d_ts_somaj.l4  0.0066105 0.0122221  0.541 0.591158
d_log_pib.l5  0.2885726 0.2348971  1.229 0.225373
ts_var_pib.l5 -0.0010709 0.0013933 -0.769 0.445962
ts_inflatie.l5 -0.0133150 0.0048255 -2.759 0.008230 **
d_log_dobanda.l5 0.0189040 0.0407501  0.464 0.644860
d_ts_curs.l5 -0.1147033 0.0571374 -2.007 0.050466 .
d_ts_somaj.l5  0.0131834 0.0122687  1.075 0.288061
const         0.0315244 0.0106339  2.965 0.004749 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.03213 on 47 degrees of freedom
Multiple R-squared: 0.5305,   Adjusted R-squared: 0.2308
F-statistic: 1.77 on 30 and 47 DF,  p-value: 0.0387

```

Figura 3.3.2. Modelul VAR pentru PIB

Sursa: Prelucrarea datelor de către autor

- **d_ts_curs.14** (cursul de schimb cu 14 perioade întârziere): coeficient negativ (-0.199) și foarte semnificativ (p=0.0009)
- **ts_inflatie.15** (inflația cu 15 perioade întârziere): coeficient negativ (-0.013) și semnificativ (p=0.008)
- **d_ts_somaj.13** (șomajul cu 13 perioade întârziere): coeficient pozitiv (0.029) și semnificativ (p=0.025)
- **d_ts_curs.15** (cursul de schimb cu 15 perioade întârziere): coeficient negativ (-0.115) și marginal semnificativ (p=0.05)
- **d_ts_somaj.12** (șomajul cu 12 perioade întârziere): coeficient pozitiv (0.023) și marginal semnificativ (p=0.079)

- **Constanta:** pozitivă (0.032) și foarte semnificativă ($p=0.005$)
- Cursul de schimb are un impact negativ asupra creșterii PIB-ului: o depreciere a monedei (creștere a cursului) reduce creșterea economică.
- Inflația la 15 perioade întârziere are un efect negativ asupra PIB-ului.
- Somajul are un efect pozitiv surprinzător (posibil datorită mecanismelor de feedback sau specificului datelor).
- $R^2 = 0.5305$: Modelul explică ~53% din variația creșterii PIB-ului.
- R^2 ajustat = 0.2308: Mult mai scăzut, indicând posibilă supra-speciere (prea multe variabile pentru dimensiunea eșantionului).
- F-statistic = 1.77 ($p=0.0387$): Modelul este semnificativ global, dar slab.

3.4 Testul de cauzalitate Granger

```
ts_inflatie -> d_log_pib : p-value = 0.3612
d_log_dobanda -> d_log_pib : p-value = 0.744
d_ts_curs -> d_log_pib : p-value = 0.0087 *CAUZAL*
d_ts_somaj -> d_log_pib : p-value = 0.8148
```

Figura 3.4.1. Testul de cauzalitate Granger

Sursa: Prelucrarea datelor de către autor

Cursul de schimb (d_ts_curs) → PIB (d_log_pib)

- $p\text{-value} = 0.0087 (< 0.05)$ → relație semnificativă
- Interpretare:
 - Modificările cursului de schimb au o influență statistică asupra creșterii PIB-ului.
 - Posibile mecanisme economice:
 - O depreciere a monedei poate stimula exporturile (crește PIB-ul).
 - O apreciere puternică poate reduce competitivitatea, afectând PIB-ul negativ.
 - Concluzie: Politicile de stabilizare a cursului ar putea avea impact asupra creșterii economice.

3.5 Functia de raspuns la impuls (IRF)

```
Impulse response coefficients
$d_ts_curs
  d_log_pib
[1,] 0.000000000
[2,] -0.001602128
[3,] -0.006345398
[4,] 0.002689245
[5,] -0.010464856
[6,] -0.010903564
[7,] 0.001629242
[8,] 0.004068532
[9,] -0.002388747
[10,] -0.004525307
[11,] -0.001422664

Lower Band, CI= 0.95
$d_ts_curs
  d_log_pib
[1,] 0.000000000
[2,] -0.007309683
[3,] -0.010656338
[4,] -0.004739231
[5,] -0.014098725
[6,] -0.014278276
[7,] -0.004621004
[8,] -0.001532923
[9,] -0.006403018
[10,] -0.008425288
[11,] -0.006117510

Upper Band, CI= 0.95
$d_ts_curs
  d_log_pib
[1,] 0.000000000
[2,] 0.004309926
[3,] 0.001064338
[4,] 0.007792099
[5,] -0.003360198
[6,] -0.002096372
[7,] 0.006635089
[8,] 0.007958751
[9,] 0.003843624
[10,] 0.001789327
[11,] 0.003837795
```

Figura 3.5.1. Functia de raspuns la impuls

Sursa: Prelucrarea datelor de către autor

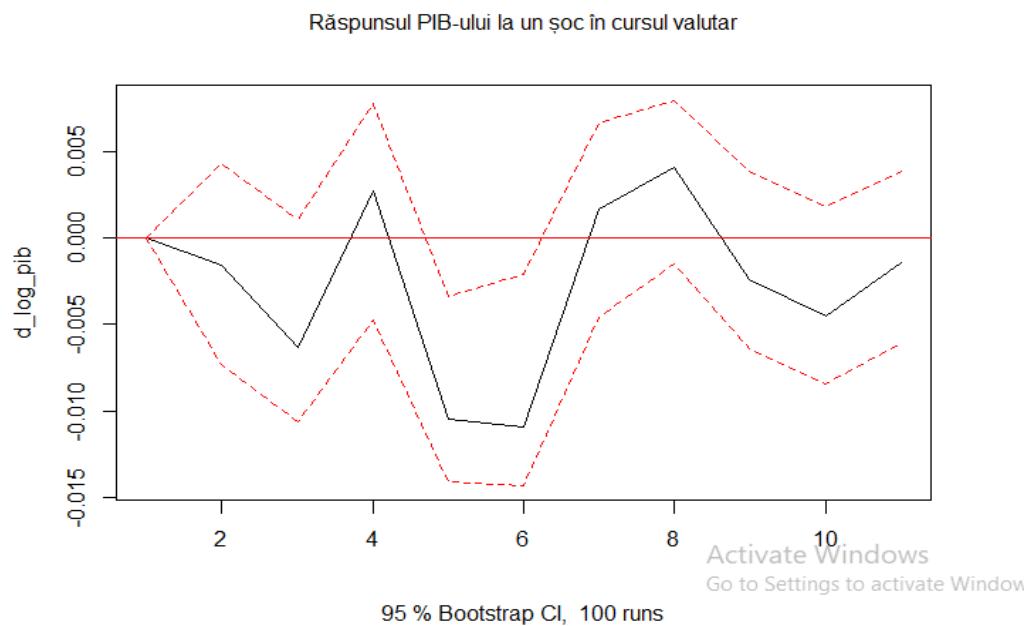


Figura 3.5.2. Grafic pentru IRF

Sursa: Prelucrarea datelor de către autor

1. Impact imediat (perioada 1):
 - Nicio reacție (0.000) – PIB-ul nu răspunde instantaneu la un şoc valutar.
2. Pe termen scurt (perioadele 2-6):
 - Efect negativ semnificativ
 - Perioada 2: -0.0016 (dar intervalul de încredere include 0, deci nu este semnificativ statistic)
 - Perioada 3: -0.0063 (intervalul de încredere confirmă semnificația)
 - Perioada 5: -0.0105 (cel mai puternic impact negativ)
 - Interpretare: O depreciere bruscă a monedei (creștere a cursului) reduce creșterea economică pe termen scurt.
3. Pe termen mediu (perioadele 7-11):
 - Recuperare parțială, dar cu volatilitate
 - Perioada 7: ușor pozitiv (+0.0016, dar nesemnificativ)
 - Perioada 8: +0.0041 (dar intervalul de încredere include 0)
 - Perioada 10: revenire la efect negativ (-0.0045)
 - Interpretare: Impactul şocului valutar persistă, dar cu o atenuare treptată.

4. Intervalul de încredere (CI 95%)

- Efectul este semnificativ statistic în perioadele 3, 5, 6, 10 (intervalele nu includ 0).
- În alte perioade, efectul este mai puțin clar din cauza variației mari.

Concluzii economice:

- Deprecierea monedei afectează negativ PIB-ul pe termen scurt, posibil datorită:
 - Creșterea costurilor de import (dacă economia depinde de importuri).
 - Presiuni inflaționiste care reduc consumul).
- Pe termen lung, efectul se atenuează, dar nu dispare complet, sugerând că ajustările economice (ex: creșterea exporturilor datorită cursului favorabil) nu compensează imediat șocul negativ.
- Politicile de stabilizare (ex: măsuri de protecție a monedei sau stimulente pentru exporturi) ar putea fi necesare pentru a atenua impactul.

3.6 Descompunerea variantei

	d_log_pib	ts_var_pib	ts_inflatie	d_log_dobanda	d_ts_curs	d_ts_somaj
[1,]	1.0000000	0.0000000000	0.000000000	0.000000000	0.000000000	0.000000000
[2,]	0.9689877	0.0007941703	0.006279790	0.006950352	0.002238827	0.01474913
[3,]	0.8623381	0.0502563896	0.006837961	0.010154169	0.032737997	0.03767538
[4,]	0.8127096	0.0472217929	0.046586833	0.012331588	0.035944012	0.04520622
[5,]	0.7493671	0.0442369935	0.043508857	0.018248918	0.103587279	0.04105086
[6,]	0.6663745	0.0454965660	0.056206788	0.023958297	0.160463731	0.04750011
[7,]	0.6609860	0.0452519634	0.057226983	0.024334821	0.159919182	0.05228109
[8,]	0.6374154	0.0444058718	0.072432703	0.023955293	0.162374846	0.05941588
[9,]	0.6386417	0.0438349019	0.071524494	0.023965900	0.163314240	0.05871879
[10,]	0.6272497	0.0444497050	0.075389738	0.024103832	0.170965728	0.05784128

Figura 3.6.1. Descompunerea variantei pentru modelul VAR

Sursa: Prelucrarea datelor de către autor

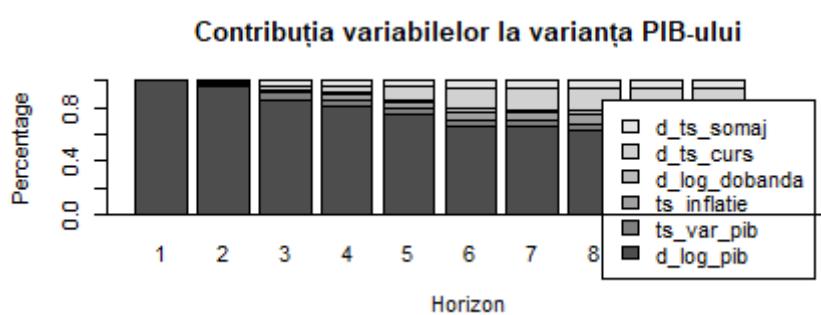


Figura 3.6.2. Contributia variabilelor la varianta PIB-ului

Sursa: Prelucrarea datelor de către autor

1. Dominanța proprie:

- În prima perioadă, 100% din variația PIB-ului este explicată de propriile sale șocuri.
- Contribuția scade treptat la 62.7% până în perioada a 10-a, dar rămâne dominantă.

2. Contribuția altor variabile:

- Cursul de schimb (d_ts_curs):
 - Crește de la 0% la 17.1% până în perioada a 10-a, devenind al doilea factor ca importanță.
- Șomajul (d_ts_somaj):
 - Contribuție relativ stabilă între 1.5%-5.9%.
- Inflația (ts_inflatie):
 - Crește de la 0% la 7.5%.
- Rata dobânzii (d_log_dobanda):
 - Contribuție minoră (sub 2.5%).
- Variația PIB (ts_var_ptb):
 - Contribuție constantă (4-4.5%).

CONCLUZII

1. Inflația: caracteristici și comportament

- Seria ratei inflației a fost:
 - **Nestaționară**, dar devine staționară după o diferențiere;
 - **Sezonieră**, cu tipar trimestrial repetitiv;
 - **Guvernată de un trend stochastic**, nu determinist;
 - Puternic afectată de crize (ex: șoc inflaționist în 2022).

2. Prognoza inflației: performanța modelelor

- Compararea modelelor a evidențiat că:
 - **SARIMA(0,1,1)(0,1,1)[4]** a fost cel mai precis, captând atât trendul cât și sezonalitatea;
 - **ARIMA(0,1,1)** a subestimat inflația, oferind o prognoză plată;
 - **Holt-Winters** a supraestimat constant inflația și nu a surprins șocurile.

Concluzie economică: Pentru variabile cu sezonalitate clară și volatilitate mare (ex. inflația), modelele SARIMA sunt preferabile față de ARIMA sau Holt-Winters.

3. Relații între variabile macroeconomice (analiză multivariată)

- **Cursul de schimb influențează PIB-ul** (test Granger: $p = 0.0087$);
- **Inflația și dobânda** devin predictori importanți ai PIB-ului pe termen lung (18% și 17% contribuție în descompunerea varianței);
- **Șomajul** are impact redus, dar constant;
- **Nu există relații stabile de cointegrare** între variabile, ceea ce reflectă lipsa unei traекторii comune pe termen lung între indicatorii economici principali (ex: PIB, curs, dobândă).

LISTĂ DE TABELE

Tabelul 2.1.1. Indicatori statistici pentru determinarea tipului de trend.....	pag. 9
Tabelul 2.2.1. Analiza comparativă a testelor în funcție de inflație.....	pag. 11
Tabelul 2.4.1. Comparație modele ARIMA.....	pag. 17
Tabelul 2.4.2. Comparație modele SARIMA.....	pag. 18
Tabelul 2.6.1. Performanțele celor două modele.....	pag. 26

LISTĂ DE FIGURI

Figura 2.1.1. Rata inflației și trendul determinist	pag. 7
Figura 2.1.2. Rezultatele regresiei liniare aplicate asupra inflației	pag. 8
Figura 2.1.3. Rezultatele testului ADF	pag. 8
Figura 2.2.1. Evoluția ratei inflației în România	pag. 9
Figura 2.2.2. Rezultatele testului KPSS	pag. 10
Figura 2.2.3. Inflația diferențiată	pag. 11
Figura 2.2.4. Rezultatele retestării	pag. 11
Figura 2.3.1. Sezonalitatea ratei inflației	pag. 13
Figura 2.3.2. Decompoziția aditivă	pag. 13
Figura 2.3.3. Funcția de autocorelație	pag. 14
Figura 2.3.4. Împărțirea în set de antrenare și set de testare	pag. 14
Figura 2.3.5. Rezultatele erorilor de prognoză	pag. 15
Figura 2.3.6. Prognoza inflației – model Holt-Winters	pag. 15
Figura 2.4.1. Identificare model ARIMA	pag. 16
Figura 2.4.2. Identificare model optim ARIMA	pag. 17
Figura 2.4.3. Erorile modelului ARIMA	pag. 17
Figura 2.4.4. Identificare model optim SARIMA	pag. 18
Figura 2.4.5. Erorile modelului SARIMA	pag. 19
Figura 2.4.6. Test Ljung-Box ARIMA	pag. 20
Figura 2.4.7. Test Ljung-Box SARIMA	pag. 21
Figura 2.4.8. Diagrama compusă de diagnostic - SARIMA	pag. 22
Figura 2.4.9. Prognoza inflației - SARIMA	pag. 23
Figura 2.4.10. Testul Jarque-Bera pentru modelul SARIMA(0,1,1)(0,1,1)[4]	pag. 23

Figura 2.4.11. Testul ARCH pentru SARIMA(0,1,1)(0,1,1)[4]	pag.24
Figura 2.5.1. Prognoza ARIMA pentru rata inflației și intervalele de încredere	pag. 24
Figura 2.5.2. Prognoza inflației cu modelul ARIMA	pag. 25
Figura 2.5.3. Prognoza inflației cu modelul SARIMA	pag. 26
Figura 2.6.1. Compararea erorilor de prognoză pentru modelele Holt-Winters și SARIMA (MAE și RMSE)	pag. 27
Figura 2.6.2. Compararea modelelor SARIMA și Holt-Winters	pag. 28
Figura 2.6.3. Compararea modelelor ARIMA și Holt-Winters	pag. 29
Figura 3.1.1. Rezultatele testului ADF.....	pag. 30
Figura 3.1.2. Ordinul de integrare al seriilor.....	pag. 32
Figura 3.2.1. Testul de cointegrare Johansen.....	pag. 32
Figura 3.3.1. Modelul VAR.....	pag. 33
Figura 3.3.2. Modelul VAR pentru PIB.....	pag. 34
Figura 3.4.1. Testul de cauzalitate Granger.....	pag. 35
Figura 3.5.1. Functia de raspuns la impuls.....	pag. 36
Figura 3.5.2. Grafic pentru IRF.....	pag. 37
Figura 3.6.1. Descompunerea variantei pentru modelul VAR.....	pag. 38
Figura 3.6.2. <i>Contributia variabilelor la varianta PIB-ului.....</i>	pag. 38

ANEXE

Anul	PIB (milioane lei)	Variata procentuala a PIB-ului fara de perioada corespunzatoare din anul precedent	IPC(%)	Rata inflatiei(%)	Rata dobânzii(%)	Cursul valutar(EURO in LEI)	Rata şomajului
T1 2004	55183.3	8	102.97	3	21.25	4.0573	7.9
T2 2004	59104.2	9.2	101.52	1.5	21.25	4.0669	7.2
T3 2004	63542.3	10.6	102.46	2.5	20.75	4.0937	6.0
T4 2004	66858.6	12.6	102.68	2.7	17.96	3.9888	7.9
T1 2005	68522.5	6.7	101.91	1.9	15.69	3.7093	7.3
T2 2005	67966.4	5.5	102.51	2.5	8.45	3.6204	7.2
T3 2005	734014	2.8	101.51	1.5	8	3.5271	7.2
T4 2005	763716	4.6	102.28	2.3	7.5	3.6367	6.6
T1 2006	80177.3	4.9	102.04	2	7.5	3.5640	6.8
T2 2006	83780.8	11.4	101.09	1.1	8.5	3.5154	7.1
T3 2006	87229.6	8.3	100.38	0.4	8.5	3.5423	7.2
T4 2006	91574.9	7.4	101.2	1.2	8.75	3.4762	6.9
T1 2007	97733	6.7	101.11	1.1	8.75	3.3817	6.5
T2 2007	103513.5	7	101.06	1.1	7.5	3.2820	6.5
T3 2007	107532.3	6.2	101.54	1.5	7	3.2346	6.2
T4 2007	116512.3	8.7	102.84	2.8	7.5	3.4506	6.1
T1 2008	125112.2	10.4	102.31	2.3	7.5	3.6892	6.3
T2 2008	132545.2	11.2	101.62	1.6	10	3.6525	5.6
T3 2008	139231.9	11.1	101.12	1.1	9.75	3.5771	5.4
T4 2008	142942.1	5.8	101.6	1.6	10.25	3.8119	5.8
T1 2009	125688.4	-5.2	102.27	2.3	10.25	4.2662	6.9
T2 2009	131656.7	-6.9	100.97	1	9.5	4.1923	6.3
T3 2009	132382.4	-6.2	100.07	0.1	9	4.2247	6.8
T4 2009	141194	-4	101.19	1.2	8	4.2658	6.8
T1 2010	128656	-3.1	102.33	2.3	7	4.1155	8.1
T2 2010	134612.1	-3	100.71	0.7	6.25	4.1807	6.8
T3 2010	137395.5	-5	103.08	3.1	6.25	4.2547	6.9
T4 2010	139783.9	-4.1	101.53	1.5	6.25	4.2884	7.3
T1 2011	145184	1.3	102.02	2	6.25	4.2246	7.6
T2 2011	144770	1.2	101.36	1.4	6.25	4.1347	7.2
T3 2011	148423.6	4.1	99.23	-0.8	5.75	4.2575	7.2
T4 2011	148857.4	0.9	100.74	0.7	5.5	4.3347	7.7
T1 2012	1504715	2.2	101.23	1.2	5.25	4.3528	7.6
T2 2012	155830.8	3.7	100.68	0.7	5.25	4.4247	6.9
T3 2012	156157.5	0.5	101.36	1.4	5.25	4.5217	6.8
T4 2012	158755	2.2	101.47	1.5	5.25	4.5244	6.9
T1 2013	1527916	2.3	102	2	5.25	4.3852	7.5
T2 2013	156374.5	2	100.4	0.4	5.25	4.3980	7.5
T3 2013	159757.6	4.6	99.42	-0.6	4.5	4.4412	7.0
T4 2013	162710.4	5.4	99.34	-0.1	4	4.4513	7.2
T1 2014	163558.1	4.7	101.3	1.3	3.5	4.5018	7.2
T2 2014	166278.4	2.4	100.28	0.3	3.5	4.4272	6.7
T3 2014	168594.9	4	99.59	-0.4	3.25	4.4148	6.5
T4 2014	170473.6	3.5	100.01	0	2.75	4.4343	6.7
T1 2015	175748.8	3.5	100.66	0.7	2.25	4.4508	7.4
T2 2015	173272.6	2.5	99.84	-0.2	1.75	4.4433	6.7
T3 2015	180384.3	2.9	97.76	-2.2	1.75	4.4282	6.5
T4 2015	183142.9	3	100.54	0.5	1.75	4.4568	6.6
T1 2016	181723.1	4.2	99.27	-0.7	1.75	4.4326	6.6
T2 2016	187709.5	5.9	99.95	0	1.75	4.4379	5.9
T3 2016	188571.7	4.1	99.73	-0.3	1.75	4.4652	5.7
T4 2016	194124.8	4.7	100.5	0.5	1.75	4.5072	5.5
T1 2017	204555.2	6.1	99.96	0	1.75	4.5206	5.5
T2 2017	208139.6	6.6	100.5	0.5	1.75	4.5517	4.8
T3 2017	218010.9	9.1	100.47	0.5	1.75	4.5814	4.7
T4 2017	220915	7	102.1	2.1	1.75	4.6166	4.7
T1 2018	228785.5	4.2	101.52	1.5	2	4.6553	4.7
T2 2018	237405.2	5.5	101.16	1.2	2.5	4.6520	4.1
T3 2018	244110.5	4.2	100.04	0	2.5	4.6468	3.9
T4 2018	249359	4.1	100.89	0.9	2.5	4.6537	4.1
T1 2019	254125.1	5.2	101.6	1.6	2.5	4.7351	4.1
T2 2019	264773.5	3.5	101.44	1.4	2.5	4.7477	3.8
T3 2019	270455.4	3.4	99.86	-0.1	2	4.7317	3.8
T4 2019	277234.6	4.7	100.8	0.8	2	4.7665	3.9
T1 2020	272260.5	2.4	101.1	1.1	2	4.7558	4.3
T2 2020	241958.4	-10.3	100.73	0.7	1.75	4.8366	5.4
T3 2020	269866.5	-6	99.99	0	1.5	4.8446	5.2
T4 2020	285544	-1.4	100.31	0.3	1.25	4.8713	5.2
T1 2021	284666.1	-0.1	102.01	2	1.25	4.8782	6.1
T2 2021	291283.2	15.4	101.29	1.3	1.25	4.9235	5.1
T3 2021	303494.6	6.9	101.78	1.8	1.25	4.9314	5.3
T4 2021	312840.8	2.4	102.67	2.7	1.5	4.9486	5.9
T1 2022	330681.7	6.3	102.99	3	2.5	4.9461	6.0
T2 2022	345529.5	5	106.33	6.3	3.75	4.9449	5.3
T3 2022	3532419	3.7	102.62	2.6	5.5	4.9143	5.4
T4 2022	359937	4.5	103.35	3.4	6.75	4.9207	5.8
T1 2023	368302.5	2.4	102.01	2	7	4.9189	5.8
T2 2023	392481.7	1.1	102.32	2.3	7	4.9481	5.4
T3 2023	404043.5	1.9	101.26	1.3	7	4.9492	5.4
T4 2023	419726.2	3	101.36	1.4	7	4.9636	5.8
T1 2024	427767.4	0.5	101.96	2	7	4.9735	5.3
T2 2024	439862.8	0.9	100.64	0.6	7	4.9751	5.0
T3 2024	444604.3	1.2	101	1	6.75	4.9745	5.6
T4 2024	453833.1	0.7	101.29	1.3	6.75	4.9752	5.9

Sursele de date sunt:

- 1.<https://www.cursbnr.ro>
2. Institutul Naţional de Statistică, disponibil la: <https://insse.ro/cms/ro>
3. Banca Naţională a României, disponibil la: <https://www.bnro.ro/home-mobile.aspx>
4. Agenția Națională pentru Ocuparea Forței de Muncă, disponibil la: <https://www.anofm.ro/>

BIBLIOGRAFIE

1. Dictionar juridic Rubinian, disponibil la:
https://www.rubinian.com/dictionar_detalii.php?id=4431
2. Aurel Iancu, Sinteză privind modelarea fragilității sistemului finanțier în INSTITUTUL NAȚIONAL DE CERCETĂRI ECONOMICE, disponibil la: <https://www.studii-economice.ro/2010/seince101213.pdf>
3. <https://www.zf.ro/opinii/recesiunea-a-inceput-pe-1-iulie-2008-si-s-a-incheiat-pe-30-septembrie-2010-de-la-1-octombrie-2010-economia-a-iesit-din-recesiune-dar-revenirea-va-fi-abia-in-2013-8265516>
4. Banca Centrală Europeană, Raport anual 2008, disponibil la:
<https://www.ecb.europa.eu/pub/pdf/annrep/ar2008ro.pdf>
5. BNR, Raport anual 2008, disponibil la: <https://www.bnro.ro/home-mobile.aspx>
6. Comisia Națională de Strategie și Prognoză, Contextul actual al economiei românești și impactul coronavirusului asupra principalilor indicatori macroeconomici, disponibil la:
https://cnp.ro/wp-content/uploads/2021/07/Contextul_actual_al_economiei_romanesti_si_impactul_coronavirusului_asupra_principalilor_indicatori_macleconomici.pdf
7. Impact masiv al COVID în România, disponibil la: https://www.economica.net/impact-grav-al-crizei-covid-asupra-economiei-romaniei-exista-scenariu-pentru-o-evolu-ie-in-forma-de-l-raport-oficial_182974.html
8. Dr. Cristian BĂHNĂREANU, IMPACTUL ECONOMIC AL PANDEMIEI DE COVID-19 LA ÎNCEPUTUL ANULUI 2020, disponibil la:
<https://www.ceeol.com/search/viewpdf?id=920690>
9. Institutul Național de Statistică,
https://insse.ro/cms/sites/default/files/com_presa/com_pdf/somaj_2020r.pdf
10. World Bank, <https://pubdocs.worldbank.org/en/273171492011110329/mpo-rom.pdf>
11. Assoc. Prof., PhD, Rodica PRIPOAIE, EFECTELE PANDEMIEI COVID-19 ASUPRA ȘOMAJULUI ȘI INFLAȚIEI, https://ibn.idsii.md/sites/default/files/imag_file/p-45-58.pdf